

考核时间：7.19 ~ 8.3（两周时间）

考核主要分为两个部分：（1）项目实践考核 （2）科研思维考核

第一部分：项目实践考核 （50%）

项目目标：以 Qwen3-0.6B 为基座模型，通过微调，探索在**保持通用性能可控**的前提下，同步提升模型的安全对齐能力和数学推理能力

基本要求：必须使用 <https://huggingface.co/Qwen/Qwen3-0.6B> 为基础模型，不得更换基础模型

核心目标：1. 使模型学会拒答有害/越狱问题；2. 提升模型在数学推理任务上的准确性，3. 通用能力下降控制在可接受范围内

提交内容：模型一个（0.6B，不得改变）+ 报告一份（仅一页）

打分规则：内部不公开三个数据集打分，包括安全数据、数学数据、通用数据。分数计算为 安全分数 $\times 40\%$ + 数学分数 $\times 30\%$ + 通用分数 $\times 30\%$

第二部分：科研思维考核 （50%）

具体任务：每人提出一个科研想法，并通过 2-3 分钟的报告（以 ppt 形式）将自己的想法描述清楚。

相关课题包括但不限于：大模型训练推理、多模态模型训练推理、深度伪造检测、大模型水印、人工智能评测、越狱攻防、大模型漏洞挖掘等等